

Aquisição Adaptativa de Informação para Detecção de Anomalias sob Deriva Estocástica: seleção sequencial de telemetria sob orçamento limitado

Autor: Gabriel

Revisão e estruturação acadêmica: Manus AI

Versão: Proposta de artigo e protocolo experimental

Resumo

Sistemas de detecção de anomalias são frequentemente aprimorados por meio do aumento da complexidade dos classificadores, embora a capacidade de decisão também dependa da informação que chega ao observador. A Pesquisa I associada a este trabalho estabelece que um canal de telemetria fixo impõe limites à informação disponível e que a deriva estocástica pode alterar a relação entre observação e estado oculto. Este segundo artigo investiga se um agente pode selecionar adaptativamente quais fontes de telemetria consultar para recuperar parte da utilidade discriminativa perdida sob deriva, respeitando um orçamento limitado de observação. Formulamos o problema como decisão sequencial sob observabilidade parcial, na qual o agente mantém uma distribuição de crença sobre o estado do sistema, escolhe ações de sensoriamento e atualiza essa crença após cada observação. O objetivo não é maximizar informação mútua isoladamente, mas maximizar utilidade decisória líquida de custo e atraso. Propomos hipóteses testáveis, um ambiente sintético controlado, replay temporal de dados, baselines passivos e adaptativos, métricas de desempenho, informação, custo e robustez, além de um protocolo de ablação. O estudo não afirma que a aquisição adaptativa seja universalmente superior; busca determinar em quais regimes de deriva e complementaridade entre sensores essa estratégia oferece maior utilidade por unidade de custo.

Palavras-chave: aquisição adaptativa de informação; active sensing; detecção de anomalias; observabilidade parcial; concept drift; seleção de sensores; cibersegurança.

1. Introdução

A detecção comportamental de ameaças em ambientes computacionais é tradicionalmente formulada como um problema de classificação. Dado um conjunto de eventos, fluxos ou atributos de execução, um modelo estima se o comportamento observado pertence a uma classe legítima ou maliciosa. Essa formulação é útil, mas pressupõe que o conjunto de observações já esteja definido e disponível.

Essa pressuposição torna-se problemática em ambientes de produção. Fontes de telemetria possuem custos diferentes de coleta, armazenamento, processamento, latência, privacidade e

impacto operacional. Além disso, a distribuição dos dados pode mudar ao longo do tempo. Um detector pode, portanto, enfrentar simultaneamente duas limitações: não possuir informação suficiente e não saber qual fonte de informação deveria consultar em seguida.

A primeira pesquisa deste programa trata do primeiro problema. Se o canal de observação é fixo e o processo pode ser representado por

$$S \longrightarrow Y \longrightarrow \hat{S},$$

então a desigualdade de processamento de dados estabelece

$$I(S; \hat{S}) \leq I(S; Y).$$

O classificador não pode obter mais informação sobre o estado original do que aquela contida na telemetria observada. A presente pesquisa parte de uma extensão natural: **e se o agente puder escolher adaptativamente quais partes do canal observar?**

A pergunta central é:

Sob um orçamento limitado de observação e diferentes níveis de deriva, uma política adaptativa de seleção de telemetria melhora a utilidade da detecção por unidade de custo em comparação com políticas passivas e não adaptativas?

O objetivo não é apresentar uma inteligência artificial genérica que “coleta tudo” nem assumir que modelos maiores resolvem a limitação informacional. O objetivo é testar se a aquisição sequencial de evidência pode aumentar a qualidade da decisão quando sensores possuem informação incremental heterogênea e a distribuição operacional não é estacionária.

1.1 Contribuições

Este artigo propõe quatro contribuições. Primeiro, formaliza a aquisição adaptativa de telemetria como decisão sequencial sob observabilidade parcial. Segundo, substitui a maximização isolada de entropia por uma função objetivo que combina utilidade decisória, custo de observação e atraso. Terceiro, define um protocolo experimental que separa o efeito do ganho informacional, da política de seleção e da complexidade do classificador. Quarto, propõe hipóteses falsificáveis sobre deriva, complementaridade entre sensores, eficiência de aquisição e parada racional.

O artigo é um protocolo de pesquisa: não apresenta resultados empíricos inventados. Os resultados deverão ser obtidos após a implementação do ambiente, a execução dos experimentos e a análise estatística pré-especificada.

2. Relação com a Pesquisa I

A Pesquisa I considera a telemetria como um canal de observação fixo. A Pesquisa II transforma a escolha da observação em uma variável de decisão.

Dimensão	Pesquisa I	Pesquisa II
Canal	Fixo durante a inferência	Parcialmente selecionável pelo agente
Pergunta	Quanto pode ser inferido?	O que vale a pena observar em seguida?
Limitação central	Informação ausente ou degradada	Orçamento e seleção de observações
Modelo	Cadeia de Markov de observação	Decisão sequencial sob crença
Métrica central	Informação disponível e erro mínimo	Utilidade por custo e recuperação sob deriva
Resultado esperado	Limite informacional	Política de aquisição eficiente

A continuidade conceitual pode ser expressa por

Limites de informação $\longrightarrow$ seleção de informação $\longrightarrow$ decisão informada.

A segunda pesquisa não contradiz o limite estabelecido pela primeira. Ela investiga como escolher uma observação $Y^{(a)}$ entre várias fontes disponíveis para aumentar a informação efetivamente acessível, dentro de restrições operacionais.

3. Fundamentação teórica

3.1 Active sensing e active learning

Embora a literatura frequentemente aproxime active learning, active perception e active sensing, os conceitos não são idênticos. Active learning normalmente envolve selecionar exemplos ou consultas para obter rótulos. Neste trabalho, o agente escolhe sensores ou consultas de telemetria; o rótulo do estado pode permanecer oculto até a decisão ou até a avaliação posterior. O problema é, portanto, denominado **aquisição adaptativa de informação** ou **active sensing**.

Modelos de active sensing mostram que a política ótima pode precisar considerar conjuntamente erro, atraso e esforço, em vez de maximizar uma medida estatística abstrata de informação ¹. Trabalhos de detecção por sensoriamento controlado também tratam a escolha sequencial de observações como processo de decisão no qual o agente atualiza uma crença sobre o estado após cada medição ² ³.

A contribuição específica deste artigo é aplicar essa estrutura ao problema de telemetria cibernética sob deriva, com sensores de custos e complementaridades distintos.

3.2 Estado, telemetria e ação

Seja S_t o estado oculto do sistema no instante t . Ele pode representar uma condição legítima, uma atividade maliciosa ou uma classe mais detalhada de comportamento. Seja $a_t \in \mathcal{A}$ uma ação de sensoriamento. Cada ação seleciona uma fonte, uma resolução, uma janela temporal ou uma consulta específica.

A observação seguinte é modelada por

$$Y_{t+1} \sim P(\cdot \mid S_{t+1}, a_t).$$

Quando a coleta altera o ambiente, a ação também pode influenciar a transição do estado:

$$S_{t+1} \sim P(\cdot \mid S_t, a_t).$$

No MVP, a hipótese principal será que as ações são passivas e não alteram o estado. Essa hipótese será declarada explicitamente. Uma extensão posterior poderá modelar coleta intrusiva, atraso ou efeitos de intervenção.

A ordem temporal do sistema é

$$S_t \rightarrow Y_t \rightarrow b_t \rightarrow a_t \rightarrow Y_{t+1} \rightarrow b_{t+1},$$

em que b_t é a crença do agente sobre o estado.

3.3 Estado de crença

O agente mantém uma distribuição de crença condicionada ao histórico de observações e ações:

$$b_t(s) = P(S_t = s \mid Y_{1:t}, a_{1:t-1}).$$

Após escolher a_t e receber y_{t+1} , a crença é atualizada por

$$b_{t+1}(s') \propto P(y_{t+1} \mid s', a_t) \sum_s P(s' \mid s, a_t) b_t(s).$$

Essa formulação permite que o agente saiba não apenas qual é sua classificação atual, mas também quais hipóteses permanecem plausíveis e qual observação poderia separá-las.

3.4 Ganho de informação

O ganho esperado de informação de uma ação pode ser definido por

$$IG_t(a) = H(S_t \mid \mathcal{H}_t) - \mathbb{E}_{Y_{t+1} \mid \mathcal{H}_t, a} [H(S_t \mid \mathcal{H}_t, a, Y_{t+1})],$$

onde $\mathcal{H}_t$ representa o histórico disponível ao agente. Em termos intuitivos, $IG_t(a)$ mede quanto a consulta tende a reduzir a incerteza sobre o estado.

O ganho não é necessariamente aditivo. Uma fonte pode ser altamente informativa isoladamente, mas oferecer pouca informação incremental depois que outra fonte já foi observada. Para representar esse efeito, usa-se

$$I(S; Y^{(a)} \mid Y_{1:t}),$$

em vez de assumir que a informação de cada sensor pode ser simplesmente somada.

3.5 Valor da informação orientado à decisão

A redução de entropia não é idêntica ao valor operacional. Uma observação pode reduzir incerteza sobre uma classe irrelevante para a decisão ou produzir ganho estatístico menor, mas evitar um falso negativo crítico. Por isso, definimos a utilidade de uma política π como

$$J(\pi) = \mathbb{E}_\pi \left[U(\hat{S}_T, S_T) - \lambda \sum_{t=0}^{T-1} c(a_t) - \rho T \right],$$

onde U é a utilidade da decisão, $c(a_t)$ é o custo da ação, λ pondera o custo e ρ representa a penalidade de atraso.

O valor esperado da informação de uma ação é

$$VOI_t(a) = \mathbb{E}_{y_{t+1}} [V(b_{t+1}) \mid b_t, a] - V(b_t) - \lambda c(a),$$

em que $V(b_t)$ é o valor da melhor decisão disponível com a crença atual. A política pode escolher

$$a_t^* \in \arg \max_{a \in \mathcal{A}} VOI_t(a).$$

A parada ocorre quando

$$\max_{a \in \mathcal{A}} VOI_t(a) \leq 0,$$

ou quando o agente atinge um limite de confiança, tempo ou orçamento.

4. Problema de pesquisa e hipóteses

4.1 Objetivo geral

Avaliar se uma política adaptativa de aquisição de telemetria melhora a utilidade da detecção de anomalias por unidade de custo em ambientes sujeitos a deriva estocástica.

4.2 Objetivos específicos

O primeiro objetivo específico é comparar políticas passivas, fixas, aleatórias, gulosas e aprendidas sob o mesmo orçamento. O segundo é medir quanto de informação discriminativa cada política adquire e quanto dessa informação é incremental. O terceiro é avaliar se a política adaptativa recupera desempenho quando a distribuição operacional se afasta da distribuição de treinamento. O quarto é verificar se um critério de parada reduz custo e atraso sem produzir degradação decisória inaceitável.

H1 — deriva e detector passivo

Mantendo o detector e o conjunto de sensores fixos, mudanças controladas entre as distribuições de treinamento e operação alterarão o desempenho decisório. A direção e a magnitude da alteração dependerão do tipo de deriva e da representação observada; portanto, não será assumida monotonicidade universal entre W_1 e AUROC.

H2 — recuperação adaptativa

Sob o mesmo orçamento de observação, uma política adaptativa de seleção de sensores alcançará maior utilidade esperada ou menor perda decisória do que uma política fixa não adaptativa em pelo menos uma classe de cenários de deriva.

H3 — eficiência informacional

A política adaptativa apresentará maior ganho de utilidade por unidade de custo do que políticas não adaptativas em regimes nos quais as fontes possuem informação incremental heterogênea.

H4 — parada racional

Uma política com critério de parada baseado em valor esperado da informação reduzirá o número médio de consultas e o custo total sem exceder um limite pré-especificado de degradação da decisão.

H5 — generalização

Uma política treinada em determinados tipos de deriva manterá vantagem parcial, mas não necessariamente total, quando avaliada em tipos de deriva diferentes dos observados durante

o treinamento.

5. Metodologia

5.1 Ambiente de simulação

O estudo será iniciado em um ambiente sintético controlado, no qual o estado verdadeiro é conhecido e as distribuições condicionais de cada sensor podem ser manipuladas. O estado poderá assumir duas classes, legítima e maliciosa, com possibilidade de extensão para múltiplas categorias.

As fontes de telemetria deverão possuir perfis diferentes de custo e informação:

Sensor	Exemplo de observação	Perfil esperado
Processo	árvore parent-child, imagem executável, linha de comando	baixo custo e informação estrutural
Rede	DNS, IP, fluxo e conexão	custo baixo ou médio, informação contextual
Syscall	sequência de chamadas	custo médio, informação comportamental
Memória	artefatos voláteis e regiões suspeitas	alto custo, informação potencialmente complementar
Topologia	grafo de dependências entre serviços	alto custo, informação distribuída

O ambiente deverá incluir fontes redundantes e complementares. Sem essa diferença, a política adaptativa não terá um problema real de seleção: bastará coletar sempre a fonte de maior qualidade.

5.2 Tipos de deriva

Serão considerados quatro mecanismos de deriva:

1. **Deriva marginal:** mudança em $P(X)$, mantendo aproximadamente estável a relação entre feature e classe.
2. **Deriva condicional:** mudança em $P(Y \mid S)$, alterando a evidência produzida por um mesmo estado.
3. **Mudança de prevalência:** alteração em $P(S)$, modificando a frequência relativa das classes.

4. **Deriva temporal ou topológica:** alteração da estrutura de dependências e das sequências observadas.

Para cada cenário, será calculada a distância de Wasserstein entre a distribuição de referência e a distribuição operacional. O valor de W_1 será usado como variável descritiva e explicativa, não como prova suficiente de degradação.

5.3 Políticas comparadas

O experimento deverá comparar métodos sob orçamentos equivalentes.

Política	Descrição
Passiva completa	Recebe todas as fontes desde o início; serve como teto de desempenho, não como comparação de custo justo.
Passiva econômica	Usa um subconjunto fixo escolhido antes da execução.
Aleatória	Seleciona sensores aleatoriamente respeitando o orçamento.
Round-robin	Consulta as fontes em ordem fixa.
Maior incerteza	Escolhe a fonte associada à maior incerteza prevista.
Ganho de informação por custo	Maximiza $IG_t(a)/c(a)$.
VOI adaptativo	Maximiza o valor esperado da informação líquido de custo e atraso.
Política neural	Aprende a escolher ações com base na crença, histórico e orçamento restante.

A política neural só deverá ser considerada contribuição principal se superar os baselines em cenários previamente definidos. Caso contrário, o resultado ainda poderá mostrar que uma política estatística simples é suficiente ou mais eficiente.

5.4 Arquitetura do agente

O MVP terá quatro componentes: um estimador de crença, um módulo de avaliação de ações, um seletor de sensores e um critério de parada.

telemetria inicial $\rightarrow$ crença $b_t \rightarrow$ VOI por ação $\rightarrow$ nova consulta $\rightarrow$ atualização b_{t+1} .

A extensão neural utilizará um codificador da crença e do histórico, seguido por duas cabeças: uma distribuição sobre ações e uma probabilidade de parada. A entrada deverá incluir o orçamento restante e indicadores de deriva; do contrário, a política não terá acesso às variáveis necessárias para uma decisão econômica.

5.5 Orçamento e custo

O orçamento total será definido por

$$\sum_{t=0}^{T-1} c(a_t) \leq B.$$

No primeiro experimento, cada ação poderá ter custo escalar. Em uma extensão, o custo será composto por

$$c(a) = w_1 c_{CPU}(a) + w_2 c_{storage}(a) + w_3 c_{latency}(a) + w_4 c_{privacy}(a),$$

com pesos definidos antes da avaliação. A publicação deverá relatar análise de sensibilidade a diferentes pesos.

6. Protocolo experimental

6.1 Fase A — prova de princípio sintética

A primeira fase terá estados conhecidos, sensores controláveis, custos definidos e drift parametrizado. Cada cenário será executado com múltiplas sementes aleatórias. O treino ocorrerá em uma distribuição de referência; a avaliação ocorrerá em uma sequência temporal de distribuições operacionais.

6.2 Fase B — replay temporal

A segunda fase utilizará dados históricos ou públicos organizados por tempo. O treinamento será feito em períodos anteriores e o teste em períodos posteriores. O agente só poderá acessar as variáveis correspondentes às ações que selecionou. Features ocultas para o agente não poderão entrar no estado latente por caminhos indiretos.

6.3 Fase C — ablações

Serão avaliadas as seguintes ablações: ausência de custo, ausência de drift, sensores sem complementaridade, ausência de memória histórica, ausência de critério de parada, política aleatória e política sem indicador de deriva. O objetivo é identificar qual mecanismo produz o ganho.

6.4 Reprodutibilidade

O protocolo deverá registrar sementes, versões de software, parâmetros de distribuição, custos, orçamento, critérios de parada, arquitetura, número de episódios e divisão temporal. Os resultados serão apresentados com média, desvio-padrão ou intervalo de confiança entre sementes e cenários.

7. Métricas

A métrica primária será a utilidade esperada por unidade de custo:

$$Efficiency(\pi) = \frac{\mathbb{E}[U(\hat{S}_T, S_T)]}{\mathbb{E}[\sum_t c(a_t)] + \varepsilon}.$$

Também serão reportadas as seguintes métricas:

Dimensão	Métricas
Desempenho	AUROC, AUPRC, F1, balanced accuracy e matriz de confusão.
Decisão	perda esperada, custo de falsos positivos e falsos negativos, utilidade acumulada.
Informação	entropia residual, ganho de informação acumulado e informação incremental por sensor.
Custo	custo total, número de consultas, latência e consumo relativo de orçamento.
Drift	$W_1(P_0, Q_t)$, desempenho por nível de drift e tempo de recuperação.
Parada	tempo médio até decisão, consultas por episódio e erro após parada.
Robustez	variância entre sementes, cenários e tipos de deriva.

AUROC não deverá ser a única métrica, especialmente quando a prevalência das classes variar. AUPRC e métricas de utilidade são necessárias para representar decisões em cenários desbalanceados.

8. Análise estatística

A comparação principal será feita entre políticas sob o mesmo orçamento e cenário de deriva. Para cada cenário, serão calculadas diferenças pareadas de utilidade, eficiência, custo e erro. A análise deve incluir intervalos de confiança obtidos por repetição de sementes ou bootstrap por episódio.

Será ajustado um modelo exploratório para avaliar a relação entre desempenho e deriva:

$$D_t = g(I(A; T_t), W_1(P_0, Q_t), H(A | T_t), C_t) ,$$

sem impor previamente monotonicidade. Serão comparadas formas lineares, não lineares e modelos com interação entre deriva e política. A política será considerada vantajosa quando apresentar melhoria consistente em utilidade ou eficiência, e não apenas aumento pontual de AUROC.

9. Resultados esperados e critérios de sucesso

Como este artigo apresenta um protocolo, não são afirmados resultados antes da execução. Os possíveis resultados serão interpretados segundo critérios pré-estabelecidos.

Resultado observado	Interpretação
VOI adaptativo supera políticas fixas sob o mesmo orçamento	Evidência favorável à aquisição adaptativa orientada à decisão.
Ganho ocorre apenas quando sensores são complementares	Evidência de que a estrutura informacional do canal é condição importante.
Política simples supera rede neural	Evidência de que a complexidade do modelo não é necessária para o princípio.
Política adaptativa melhora AUROC, mas não utilidade	Ganho preditivo sem benefício operacional suficiente.
Não há ganho sobre o baseline informacional	A política aprendida não acrescenta valor no regime testado.
Vantagem desaparece em drift não observado	Limitação de generalização, não necessariamente falsificação completa da ideia.
Agente coleta excessivamente	Falha do critério de custo ou parada.

O critério mínimo de sucesso será uma melhoria estatisticamente consistente de utilidade por unidade de custo em pelo menos uma família de cenários de deriva, mantendo desempenho dentro de um limite pré-especificado nos demais cenários.

10. Ameaças à validade

A primeira ameaça é a artificialidade do ambiente sintético. Sensores gerados por distribuições simples podem favorecer políticas adaptativas de maneira irrealista. Por isso, o replay temporal é necessário.

A segunda ameaça é o vazamento de informação. Se a política ou o codificador tiver acesso a features que supostamente não foram coletadas, o ganho será inválido. O pipeline deverá impor uma máscara explícita de observação.

A terceira ameaça é a definição do custo. Resultados podem mudar conforme pesos de CPU, armazenamento, latência e privacidade. A análise de sensibilidade deve ser parte do artigo, não um detalhe posterior.

A quarta ameaça é a circularidade entre a métrica de informação e o modelo. Se a mesma rede estima crença, ganho de informação e decisão, pode produzir uma vantagem aparente por calibração inadequada. O MVP deve separar, sempre que possível, estimador de crença, política e avaliador.

A quinta ameaça é a confusão entre correlação e causalidade. Aumento de W_1 associado a queda de desempenho não prova que a distância causou a queda. O desenho deve manipular tipos de deriva e comparar cenários controlados.

11. Limitações e escopo

Este trabalho não pretende resolver seleção ótima de sensores em todos os ambientes cibernéticos. O catálogo de ações será definido pelo pesquisador; o agente não descobrirá novos sensores nem controlará integralmente o sistema operacional. A primeira versão assumirá ações passivas, estado parcialmente observável e custos conhecidos ou estimáveis.

A Pesquisa III, envolvendo atacante e defensor como agentes que manipulam o canal, será deixada para trabalho futuro. Ela introduziria interação estratégica, adaptação adversarial e possíveis jogos de informação, mas não é necessária para testar a hipótese principal desta pesquisa.

12. Conclusão

A Pesquisa II propõe uma mudança do detector passivo para o agente que decide quais evidências buscar. Seu problema central é a aquisição adaptativa de informação sob orçamento limitado e deriva estocástica. A formulação adequada é sequencial: o agente mantém uma crença, seleciona uma observação, atualiza sua crença e decide se deve continuar coletando.

A contribuição não deverá ser apresentada como a simples superioridade de uma rede neural. O teste decisivo é se uma política adaptativa consegue obter maior utilidade decisória por unidade de custo do que políticas passivas e não adaptativas, especialmente quando sensores

são complementares e o ambiente muda. A informação mútua, a entropia residual e a distância de Wasserstein serão instrumentos de análise; a utilidade operacional e a eficiência de aquisição serão os critérios de sucesso.

A Pesquisa I define o limite do que pode ser inferido de um canal fixo. A Pesquisa II investiga como selecionar, sob restrição, as partes do canal que mais contribuem para uma decisão.

Referências

- [1] Ahmad, S.; Yu, Y. (2014). “Active Sensing as Bayes-Optimal Sequential Decision-Making.” Proceedings of the Conference on Uncertainty in Artificial Intelligence. Texto e registro acadêmico.
- [2] Joseph, G.; Zhong, C.; Gursoy, M. C. et al. (2024). “Anomaly Detection via Learning-Based Sequential Controlled Sensing.” IEEE Sensors Journal. Registro IEEE.
- [3] Joseph, G.; Zhong, C.; Gursoy, M. C. et al. (2020). “Anomaly Detection via Controlled Sensing and Deep Active Inference.” IEEE conference publication. Registro IEEE.
- [4] Shannon, C. E. (1948). “A Mathematical Theory of Communication.” Bell System Technical Journal, 27(3), 379–423; 27(4), 623–656.
- [5] Fano, R. M. (1961). Transmission of Information: A Statistical Theory of Communications. MIT Press.
- [6] Villani, C. (2009). Optimal Transport: Old and New. Springer.